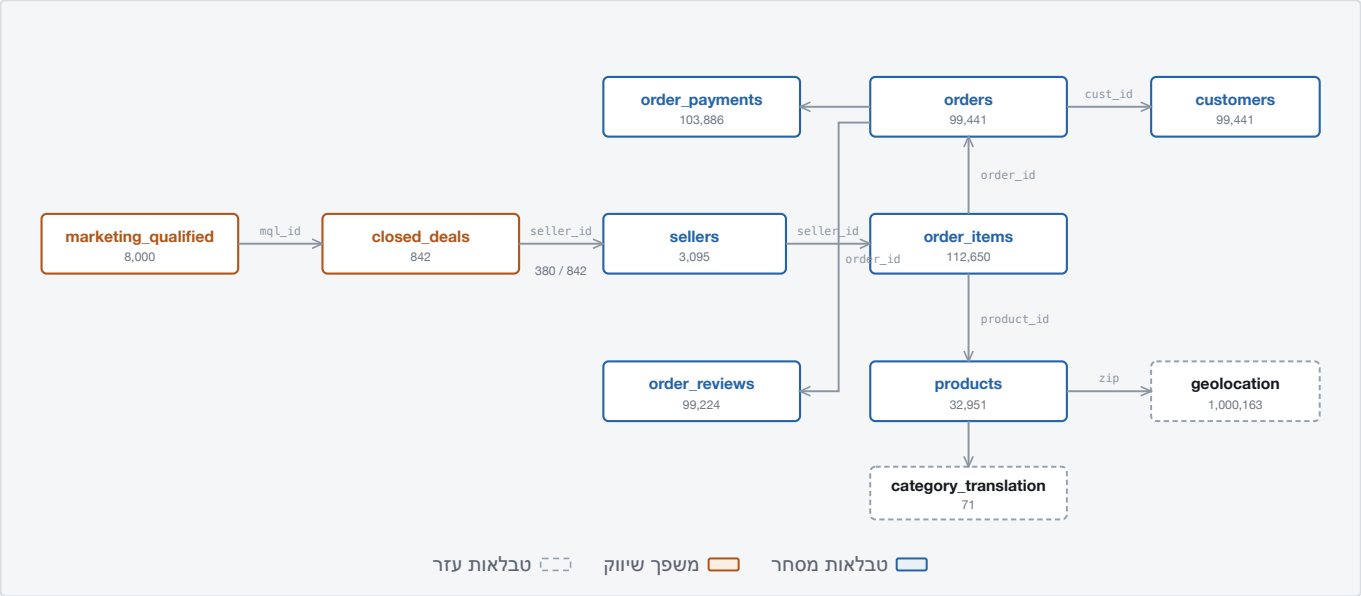
מבנה הנתונים של Olist

פרויקט גמר בניתוח שיווקי. **11 טבלאות**, **1,559,764 שורות**, משני מאגרים ב-Kaggle. כל הקבצים נמצאים בתיקייה `data/raw`

שני מאגרים שמתחברים בנקודה אחת. טבלאות **המסחר** מתעדות מה קרה בפלטפורמה: הזמנות, פריטים, תשלומים וביקורות. טבלאות **משפך השיווק** מתעדות מאיפה הגיעו המוכרים. הטבלה `closed_deals` היא הגשר: יש בה גם מזהה ליד וגם מזהה מוכר, וזה מה שהופך את השאלה על ערך לפי ערוץ לשאלה שאפשר לענות עליה.

כל מספר במסמך הזה נמדד מקובצי ה-CSV עצמם, ולא הועתק מתיעוד חיצוני.

הקשרים בין הטבלאות



משפך השיווק: מאיפה הגיעו המוכרים

olist_marketing_qualified_leads

8,000 × 4

כל ליד שהגיע לסטטוס מוכשר, מסומן בערוץ הגיוס שהביא אותו. זו נקודת המוצא של כל הניתוח.

> שורה אחת שווה **ליד אחד**. הערך `mql_id` ייחודי.

עמודה	טיפוס	הערה
`mql_id` PK	str	מזהה הליד
`first_contact_date`	date	מיוני 2017 עד מאי 2018
`landing_page_id`	str	דף הנחיתה
`origin`	str	**הערוץ**, עשרה ערכים, 0.8% חסרים

הערוצים:

organic_search, paid_search, social, direct_traffic, email, referral, display, other_publicities, other, unknown

olist_closed_deals

842 × 14

לידים שהפכו למוכרים, שיעור המרה של 10.5 אחוז. זו טבלת הגשר: יש בה גם מזהה הליד וגם מזהה המוכר, ושום דבר אחר לא מחבר בין שני המאגרים.

> שורה אחת שווה **עסקה אחת שנסגרה**. שני המזהים ייחודיים.

עמודה	טיפוס	הערה
`mql_id` FK	str	מתאים ללידים, 842 מתוך 842
`seller_id` FK	str	מתאים למוכרים, **380 מתוך 842**
`won_date`	datetime	מדצמבר 2017 עד נובמבר 2018
`business_segment`	str	תחום הפעילות של המוכר
`lead_type`	str	סוג הליד
`lead_behaviour_profile`	str	21% חסרים
`business_type`	str	משווק או יצרן
`sdr_id / sr_id`	str	אנשי המכירות שטיפלו
`has_company / has_gtin`	bool	92.5% חסרים, לא שמיש
`declared_monthly_revenue`	float	**אפס ב-797 מתוך 842**
`declared_product_catalog_size`	float	773 חסרים
`average_stock`	str	טווח מלאי מוצהר

אין להשתמש בשדות `declared_` כמדד ערך. אלה הצהרות של הליד בזמן ההרשמה, ברובן אפס או חסרות. ערך אמיתי חייב להיות מחושב מנתוני ההזמנות.

טבלאות המסחר: מה המוכרים עשו בפועל

olist_orders

99,441 × 8

שורה לכל הזמנה, עם הסטטוס שלה וחמש חותמות זמן של מחזור החיים. זהו עמוד השדרה של נתוני הפלטפורמה.

> שורה אחת שווה **הזמנה אחת**. הערך `order_id` ייחודי.

עמודה	טיפוס	הערה
`order_id` PK	str	מזהה ההזמנה
`customer_id` FK	str	מקשר לטבלת הלקוחות
`order_status`	str	97% סופקו
`order_purchase_timestamp`	datetime	מספטמבר 2016 עד אוקטובר 2018
`order_approved_at`	datetime	מועד אישור
`order_delivered_carrier_date`	datetime	מסירה לשליח
`order_delivered_customer_date`	datetime	3.0% חסרים
`order_estimated_delivery_date`	datetime	מועד מובטח

פילוח סטטוסים: סופקו 96,478, נשלחו 1,107, בוטלו 625, לא זמינות 609, חויבו 314, בעיבוד 301. לעבודה על הכנסות יש לסנן לסטטוס שסופק.

olist_order_items

112,650 × 7

שורות פריט. **הטבלה היחידה שמקשרת מוכר לכסף**, וכל מספר הכנסות בפרויקט מתחיל כאן.

> שורה אחת שווה **פריט אחד בהזמנה**. המפתח הוא צירוף של מזהה הזמנה ומספר פריט.

עמודה	טיפוס	הערה
`order_id` FK	str	מקשר להזמנות
`order_item_id`	int	מספר סידורי בתוך ההזמנה
`product_id` FK	str	מקשר למוצרים
`seller_id` FK	str	מקשר למוכרים
`shipping_limit_date`	datetime	מועד אחרון למסירה
`price`	float	**הכנסת הפריט, בריאל ברזילאי**
`freight_value`	float	משלוח, אינו הכנסה של המוכר

הזמנה עם פריטים מכמה מוכרים מופיעה פעם אחת לכל מוכר. לרכיב ההכנסות בציון מסכמים את `price` לפי `seller_id`.

olist_order_reviews

99,224 × 7

ציוני ביקורת של לקוחות לכל הזמנה. זהו רכיב שביעות הרצון בציון ערך המוכר.

> בערך **שורה אחת להזמנה, אבל לא בדיוק**. אף אחד משני המזהים אינו ייחודי.

עמודה	טיפוס	הערה
`review_id`	str	**98,410 ערכים שונים, לא ייחודי**
`order_id` FK	str	**98,673 ערכים שונים, לא ייחודי**
`review_score`	int	בין 1 ל-5, ממוצע 4.09
`review_comment_title`	str	ברובו ריק
`review_comment_message`	str	58.7% חסרים
`review_creation_date`	datetime	מועד יצירה
`review_answer_timestamp`	datetime	מועד מענה

חובה לצמצם לביקורת אחת לכל הזמנה לפני חיבור. חיבור ישיר מנפח את מספר השורות וסופר הכנסות פעמיים. הציונים מוטים כלפי מעלה: חמישה כוכבים 57,328, ארבעה 19,142, שלושה 8,179, שניים 3,151, אחד 11,424.

olist_order_payments

103,886 × 5

איך שולמה כל הזמנה. הקשר שימושי, אבל לא מקור ההכנסות, כי הזמנה אחת יכולה להתפצל לכמה שורות תשלום.

> שורה אחת שווה **תשלום אחד בהזמנה**.

עמודה	טיפוס	הערה
`order_id` FK	str	מקשר להזמנות
`payment_sequential`	int	מספר תשלום בפיצול
`payment_type`	str	אשראי 76,795, בולטו 19,784
`payment_installments`	int	מספר תשלומים
`payment_value`	float	ברמת ההזמנה, לא לפי מוכר

להכנסות של מוכר יש להשתמש ב-`order_items.price`. אי אפשר לייחס את `payment_value` למוכר מסוים בהזמנה משותפת.

olist_sellers

3,095 × 4

רישום המוכרים. זהו יעד החיבור של `closed_deals` ויחידת הניתוח של ציון ערך המוכר.

> שורה אחת שווה **מוכר אחד**. הערך `seller_id` ייחודי.

עמודה	טיפוס	הערה
`seller_id` PK	str	מזהה המוכר
`seller_zip_code_prefix`	int	מקשר לגאולוקציה
`seller_city`	str	טקסט חופשי, כתיב לא אחיד
`seller_state`	str	קוד מדינה ברזילאי

כל 3,095 המוכרים מופיעים ב-`order_items`, מאה אחוז. הטבלה הזו מכילה רק מוכרים שבאמת מכרו, ולכן עסקה שלא נמצאת כאן היא מוכר שלא מכר. רק **380** ניתנים לשיוך לערוץ גיוס.

olist_customers

99,441 × 5

רשומות קונים, אחת לכל הזמנה ולא אחת לכל אדם.

> שורה אחת שווה **לקוח של הזמנה אחת**.

עמודה	טיפוס	הערה
`customer_id` PK	str	ייחודי, נוצר לכל הזמנה
`customer_unique_id`	str	**96,096 שונים, האדם האמיתי**
`customer_zip_code_prefix`	int	מקשר לגאולוקציה
`customer_city`	str	עיר
`customer_state`	str	מדינה

לספירת אנשים יש להשתמש ב-`customer_unique_id` ולא ב-`customer_id`, שנוצר מחדש בכל הזמנה ולכן קונה חוזר נראה כמו קונה חדש.

מוצרים וטבלאות עזר

olist_products

32,951 × 9

קטלוג המוצרים, עם קטגוריה ומידות פיזיות.

> שורה אחת שווה **מוצר אחד**. יש 73 קטגוריות.

עמודה	טיפוס	הערה
`product_id` PK	str	מזהה המוצר
`product_category_name`	str	בפורטוגזית, 1.9% חסרים
`product_name_lenght`	float	שגיאת כתיב במקור
`product_description_lenght`	float	שגיאת כתיב במקור
`product_photos_qty`	float	מספר תמונות
`product_weight_g`	int	משקל בגרמים
`product_length_cm / height / width`	int	מידות בסנטימטרים

יש להשאיר את שגיאות הכתיב. המילה `lenght` היא השם האמיתי של העמודות בקובץ. שינוי השם שובר את היכולת לשחזר מול המקור.

product_category_name_translation

71 × 2

תרגום שמות קטגוריות מפורטוגזית לאנגלית, לתוויות קריאות בגרפים.

> שורה אחת שווה **קטגוריה אחת**.

עמודה	טיפוס	הערה
`product_category_name` PK	str	פורטוגזית
`product_category_name_english`	str	אנגלית

71 תרגומים ל-73 קטגוריות. חסרות שתיים: `pc_gamer` ו-`portateis_cozinha_e_preparadores_de_alimentos`. יש להשתמש ב-left join, אחרת המוצרים האלה נופלים.

olist_geolocation

1,000,163 × 5

רשימת נקודות ציון לפי קידומת מיקוד, לצורך מפות. אינה נחוצה לניתוח הליבה וזהו הקובץ הגדול ביותר, 58 מגהבייט.

> **הרבה שורות לכל קידומת**, 19,015 קידומות שונות.

עמודה	טיפוס	הערה
`geolocation_zip_code_prefix`	int	**לא ייחודי**, כ-53 שורות לכל אחת
`geolocation_lat / lng`	float	קואורדינטות
`geolocation_city / state`	str	עיר ומדינה

חובה לצמצם לפני חיבור. לוקחים ממוצע קואורדינטות לכל קידומת. חיבור ישיר מכפיל את מספר השורות פי 53 בערך.